

פרויקט הסיום - Capstone Project

מטרות הפרויקט:

פרויקט הגמר מהווה הזדמנות ליישם בפועל את הכלים, הגישות והעקרונות שנלמדו במהלך הקורס, תוך פתרון בעיה ממשית בעזרת מודל של ניתוח טקסט.

דרישות בסיסיות:

- כל פרויקט חייב לכלול שימוש במודל של ניתוח טקסט, אשר תפוח או תותאם על-ידי הסטודנטים.
- אין צורך להיכנס לעומק של תהליכים סטנדרטיים כמו עיבוד טבלאות או בחינת מספר מודלים פשוטים – ההתמקדות היא בניתוח טקסט.
- העבודה תתבצע בקבוצות של שני סטודנטים בלבד.
- אופן ההגשה כולל קוד, מצגת, ואופציונלית – מסמך מפורט.
- **תאריך ההגשה הסופי: יום ראשון 2.8.2026, בחצות.**

שלבי הפרויקט:

1. הגדרת הבעיה

- כל פרויקט חייב לכלול שימוש במודל של ניתוח טקסט, אשר יפותח או יותאם על-ידי הסטודנטים - **ניתן ומומלץ להשתמש בבעיה שהגדרתם בתרגיל בית 1.**
- אין צורך להיכנס לעומק של תהליכים סטנדרטיים כמו עיבוד טבלאות או בחינת מספר מודלים פשוטים – ההתמקדות היא בניתוח טקסט.
- העבודה תתבצע בקבוצות של שני סטודנטים בלבד.
- אופן ההגשה כולל קוד, מצגת, ואופציונלית – מסמך מפורט.

2. תרגום הבעיה לבעיית ניתוח טקסט

- האם מדובר במשימה של סיווג (classification), דירוג (ranking), חילול (generation), חילוץ (extraction), חיזוי ערך רציף (regression)?
- פתרון הבעיה יכול לשלב כמה מן המשימות שהוזכרו.
- ציינו כיצד כריית טקסט תסייע לכם במימוש הפתרון.

3. איסוף נתונים

- בחרו או אספו מערך נתונים מתאים – ניתן להשתמש במקורות פתוחים, נתוני חברה (באישור), או קבצים קיימים שעברו התאמה.

○ ניתן ומומלץ להשתמש בנתונים שתשתמשו בהם לתרגיל בית 1.

- להמלצות נוספות לאיסוף נתונים - עיינו בקובץ

 [Selecting a Dataset for Data-driven Projects](#)

4. מימוש הפתרון

- תכננו ויישמו מערכת כריית טקסט שתכלול שימוש בטכניקות לכריית טקסט שנלמדו בקורס

- Word Embeddings
- Topic Models
- Document Embedding
- Fitting & Fine-Tuning Supervised Text Classification Models
- Generative Language Models

- הניתוח ישמש אתכם להוצאת מידע מהטקסט שיסייע בפתרון המשימה הסופית שתפתרו. חשבו איזו טכניקה היא המתאימה ביותר לבעיה שלכם, והסבירו.

- ניתן (ומומלץ) להשתמש ב־Transfer Learning או pretrained models, במיוחד כשיש מעט דאטה.

5. הערכה וניתוח

- בצעו הערכת ביצועים עם מטריקות מתאימות למשימה שלכם.
- בצעו ניתוח שגיאות או הערכה איכותנית.
- הציגו גרף/טבלה המרכזים את התוצאות והמשמעות העסקית או היישומית.

6. הצגת הפרויקט

- צרו מצגת באורך של עד 15 דקות הכוללת:

□ תיאור הבעיה.

□ פירוט הפתרון מבוסס ניתוח טקסט.

□ תוצאות.

□ אתגרים ומסקנות.

- ההצגות יתבצעו ב-3.8.2026.

כללים ודגשים

- **תתחילו מוקדם!** פרסום העבודה מוקדם בקורס נועדה על מנת שתוכלו לחפש נתונים מתאימים ולתכנן את הפרויקט. שימו לב שתרגילי הבית הם עבודות מקדימות וחלק מהפרויקט - תכננו את העבודה כך שתבצעו חלק ממנה כבר במהלך הסמסטר.
- **התייעצו בנו!** אני ממליץ בחום לקבוע פגישת (או מספר פגישות) זום להתייעצות איתי, או עם טל, במהלך השלבים המוקדמים של העבודה על הפרויקט. אנו מציעים לכם ליווי ללא הגבלת זמן, שימוש במשאב זה חיוני להצלחה בפרויקט.
- **עבודה על תת-דגימה:** למי שבחרו לעבוד על דאטה-סט בו זמני האימון ארוכים, כדאי מאוד לעבוד עם תת-דגימה (subset) אקראית של הדאטה-סט (שמשמרת תכונות סטטיסטיות כמו התפלגות מחלקות, תת-אוכלוסיות, התפלגות פר פיצ'ר ועוד) ולבצע את רוב שלבי המחקר ופיתוח הקוד עליה, כאשר אימון והערכת ביצועים על הדאטה-סט המלא נעשים רק בנקודות קבלת החלטה (האם להמשיך להשקיע במודל א' או ב'? האם לכלול אוגמנטציה מסוימת או לא?) או במקומות בהם אתם רוצים לדווח אומדים אמינים להערכת ביצועים. ואגב, לפעמים גם את חלק מההחלטות האלה אפשר לקבל על 50% מהדאטה-סט, או 30%, וזו פשרה סבירה בין

מהירות העבודה וה-feedback loop שלכם לבין היכולת שלכם לסמוך על התוצאה של הבדיקה שאיתה אתם מקבלים החלטה.

○ שיטות מומלצות:

□ Transfer Learning (בפרט לפרויקטים עם דאטה מועט).

□ Fine-tuning על מודלים קיימים (כגון BERT, T5, spaCy).

□ Enrichment - העשרת הטקסט במידע חיצוני: הוספת תגיות POS, ניתוח תחבירי (dependency parsing), זיהוי ישויות (NER), או שילוב מקורות ידע כגון WordNet/ConceptNet כדי להעמיק את הייצוג הטקסטואלי.

□ Augmentation

○ ידע ומיומנויות מוקדמות שאני מניח שיש לכם:

□ עיבוד נתונים מקדים (preprocessing)

□ feature engineering ידני ו/או ניתוחים סטטיסטיים

□ יכולת מדידה והערכה לביצועי מודלים

הגשה

○ קוד הפרויקט (Jupyter Notebook או Google Colab, ו/או קבצי .py) - אין מגבלה על מספר הקבצים.

○ ניתן ומומלץ להגיש לינק לתיקייה ב-GitHub ולשים את הפרויקט שם - הוסיפו אותי ואת כל contributors-כ.

○ מצגת (לפי המבנה שפורט).

○ מסמך תיאור (אופציונלי, אך יכול לשפר את הציון).

○ **יש להגיש את כלל הקבצים בתיבת ההגשה עד ל-2.8.2026 בחצות.**

מבנה הציון

○ הגדרת בעיה ובחירת גישה מתאימה - 20%

○ תכנון ומימוש של כריית וניתוח טקסט - 40%

○ ניתוח תוצאות והערכת ביצועים - 25%

○ הצגה וסיכום - 15%

נספח א': רעיונות לפרויקטי סיום בניתוח טקסט

הבנת שפה (Language Understanding)

- ניתוח רגשות של ביקורות רב-תחומיות: השווא בין ביצועי שיטת Lexicon-based לבין Word Embeddings בזיהוי סנטימנט. הסבירו מה כל טכניקה "לומדת" על הטקסט ומתי כל אחת עדיפה. דאטה לדוגמה: Yelp Reviews, Amazon Reviews.
- זיהוי כוונה (Intent Detection): בנו מסווג מבוסס TF-IDF + Logistic Regression לזיהוי כוונת המשתמש בשאלות. השווא עם מסווג מבוסס Word Embeddings. הסבירו מה ייצוג TF-IDF "מפספס" לעומת ייצוג סמנטי.
- זיהוי ישויות (NER): הריצו NER על קורפוס עיתונאי, נתחו אילו ישויות שולטות בנושאים שונים. שלבו עם Topic Modeling כדי לגלות: באילו נושאים מוזכרות אילו ישויות?

יצור וסיכום טקסט (Text Generation & Summarization)

- סיכום אוטומטי Extractive: השווא שתי גישות TF-IDF-based - extractive (בחירת משפטים לפי ציון TF-IDF) לעומת TextRank (גרף דמיון בין משפטים). הציגו ROUGE scores ונתחו איכותית מה כל שיטה "מבינה" כחשוב. דאטה: CNN/DailyMail, ויקיפדיה.
- ניתוח ייצוג נושאים בכתיבה: השתמשו ב-LDA (Topic Modeling) על קורפוס כתיבה (מאמרים, ספרים) - בדקו האם הנושאים שהמודל מגלה תואמים לקטגוריות הידועות. איזה hyperparameter (מספר נושאים K) עובד הכי טוב ולמה?

חיפוש ואחזור מידע (IR & Retrieval)

- מנוע חיפוש סמנטי: בנו שני מנועי חיפוש - אחד מבוסס BM25-style (TF-IDF) ואחד מבוסס Sentence Embeddings (cosine similarity). השווא על queries אמיתיות - מתי הגישה הסמנטית עדיפה ומתי keyword-based מנצחת? הסבירו את הפשרות.
- שאלות ותשובות Extractive: בנו מערכת QA שמוצאת את הפסקה הרלוונטית בקורפוס ומחזירה את התשובה. נתחו מה גורם לכשלונות - שאלות שדורשות הבנה סמנטית לעומת שאלות keyword-based.

גילוי נושאים (Topic Modeling)

- גילוי נושאים בפורום אינטרנטי: הריצו LDA ו-NMF על Reddit/Stack Overflow, השוו בין שתי השיטות: אילו נושאים כל שיטה מגלה? מה ה-coherence score? עקבו אחר שינוי נושאים לאורך זמן (topic drift).
 - ניתוח שינויי שיח בתקשורת: בחרו קורפוס של כתבות עיתונאיות בנושא אחד על פני שנים. גלו כיצד הנושאים (topics) השתנו עם הזמן. השתמשו ב-LDA לפי תקופות ו-Word Embeddings כדי לנתח שינוי משמעות מילים.
-

🌐 עיבוד שפה מרובת-לשונית / עברית (Multilingual / Hebrew NLP)

- ניתוח רגשות בעברית: בנו מסווג סנטימנט לטקסט עברי (ביקורות, ציורים). השוו גישת Lexicon-based (עם לקסיקון עברי) לגישת Word Embeddings מאומן על עברית (AlephBERT embeddings בלבד, ללא fine-tuning). מה האתגרים הייחודיים של העברית (מורפולוגיה, ניקוד, כיוון)?
 - השוואת ייצוגי שפה בין-לשונית: טקסט מקביל (למשל ויקיפדיה בעברית ובאנגלית) - בדקו עד כמה Word Embeddings בשתי השפות מציגות מרחבים דומים. האם מילים בעלות אותה משמעות נמצאות "קרוב" זו לזו?
-

🟡 גילוי תוכן (Content Analysis)

- זיהוי חדשות מזויפות (Fake News Detection): בנו מסווג המשתמש ב-TF-IDF ובמאפייני סגנון כתיבה (אורך משפט, יחס שמות עצם/פעלים). השוו לגישה מבוססת Word Embeddings. מה המאפיינים הטקסטואליים שמבדילים מ-fake מ-real? הסבירו מה כל טכניקה "רואה".
- ניתוח נרטיב בתקשורת: בחרו אירוע חדשותי אחד ואספו כתבות ממקורות שונים (CNN, Fox, BBC). השתמשו ב-Topic Modeling ו-Sentiment Analysis כדי לנתח כיצד כל מקור "מסגר" את האירוע. מה הנושאים המודגשים? מה ה-sentiment?

נספח ב': מפת ציונים

ציון 55-65 - "זה מה שכולם יודעים לעשות"

- בחרתם בעיה נפוצה ומוגדרת היטב מראש (למשל: סיווג ביקורות חיובי/שלילי, סיווג נושאים).
- הרצתם טכניקה אחת מהקורס (למשל TF-IDF + classifier) ללא השוואה ועומק.
- הניתוח שטחי - "קיבלנו accuracy של X%" ללא הסבר מדוע.
- הדאטה פשוט ומוכן לשימוש (Kaggle off-the-shelf).
- זהו רמת "מבוא ל-NLP" - הקורס מצפה ליותר.

ציון 70 - בסיס טוב

- הגדרת הבעיה ברורה ומעניינת, הנתונים נאספו ועובדו כראוי.
- טכניקה אחת מהקורס יושמה היטב עם הערכה מסודרת (metrics מתאימות, לא רק accuracy).
- הוגשו הסברים: למה בחרתם את הטכניקה הזו? מה הגיוני בבחירה?
- הקוד עובד ומוגש כראוי.

ציון 80-89 - פרויקט טוב

לקבל ציון בטווח זה, נדרש:

- בעיה מאתגרת ומתאימה לניתוח טקסט (לא טריוויאלית).
- הדגמת הבנה עמוקה של **לפחות שתי טכניקות** מהקורס ואופן יישומן, לא רק שהשתמשתם, אלא מה הן "עושות" לטקסט.
- השוואה מסודרת בין גישות, כולל baseline, metrics, מרובות, וניתוח איכותני של שגיאות.
- ניסוי עם מספר variants (למשל: מספר נושאים שונה ב-LDA, window sizes ב-Word2Vec) עם הסבר של כל ניסוי.
- מסקנות שמגיעות מהנתונים - לא רק תוצאות.

ציון 90-100 — פרויקט מנצח

לקבל ציון בטווח זה, נדרש **הכל מלמעלה**, בנוסף:

- רמת מקצועיות גבוהה: ניסויים מסודרים, קוד נקי, הצגה ברורה.
- הבנה עמוקה של **למה** הטכניקות עובדות או נכשלות — ניתוח שגיאות מעמיק.
- חיבור בין ממצאי הניתוח לבעיה העסקית/המחקרית המקורית.
- בדרך כלל נדרש ידע קודם טוב או עבודה קשה מאוד לאורך הקורס.

- לא הרבה פרויקטים מגיעים לטווח זה - זה מצופה ומובן.

ציונים אינם מבוססים על כמות העבודה. הם משקפים את הידע, ההבנה והיכולת שלכם ביישום טכניקות ניתוח טקסט. מוסד אקדמי אינו סטארטאפ, המדד הוא לא "השקעתי הרבה" אלא "הבנתי לעומק".